

# Actividad Práctica I

## Metodologías de Gestión y Diseño de Proyectos Big Data

Máster en Big Data y Data Science - 13MBID

| Campo                                        | Contenido                                                                                                                             |
|----------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| Nombre completo                              | José Escorcía Gutiérrez                                                                                                               |
| Enlace al repositorio en GitHub              | <a href="https://github.com/josescorcía/13MBID-AP1-Jose-Escorcía.git">https://github.com/josescorcía/13MBID-AP1-Jose-Escorcía.git</a> |
| Enlace a la herramienta de gestión de tareas | <a href="https://github.com/users/josescorcía/projects/1/views/1">https://github.com/users/josescorcía/projects/1/views/1</a>         |
| Fecha                                        | 08/07/2026                                                                                                                            |

## Resumen ejecutivo

La presente memoria documenta la primera iteración de automatización de un proyecto de ciencia de datos orientado a predecir la mora futura de créditos de una entidad financiera. El trabajo combina CRISP-DM para organizar las fases analíticas, Scrum para gestionar el backlog y DataOps para automatizar tareas repetibles de visualización, validación y preparación de datos.

En esta versión se implementaron scripts independientes de las libretas, tests automatizados con PyTest, reportes de calidad, visualizaciones exportables y un pipeline DVC con tres etapas: visualización, validación de calidad y preparación de datos.

| Resultado                      | Valor |
|--------------------------------|-------|
| Registros en datos de créditos | 10127 |
| Registros en datos de tarjetas | 10127 |
| Registros en dataset procesado | 8899  |
| Columnas en dataset procesado  | 23    |
| Tests PyTest ejecutados        | 6     |
| Tests PyTest superados         | 6     |
| Reglas de calidad evaluadas    | 15    |
| Reglas en estado OK            | 15    |

## [A] Comprensión del negocio

### Determinar los objetivos de la organización

La organización corresponde a una entidad financiera que busca obtener conocimiento a partir de su base histórica de créditos otorgados y de información complementaria sobre tarjetas de crédito. El objetivo de negocio es mejorar la capacidad de anticipar clientes con riesgo de mora para apoyar decisiones comerciales y de riesgo crediticio.

Para esta primera actividad práctica, el objetivo se amplía desde la construcción de un MVP hacia la estandarización del proceso de ciencia de datos: versionar datos, reproducir experimentos, automatizar flujos, separar scripts de notebooks, documentar decisiones y preparar una base sólida para futuras fases de modelado y despliegue.

### Evaluación de la situación

| Elemento          | Situación identificada                                             | Implicación para el proyecto                                                 |
|-------------------|--------------------------------------------------------------------|------------------------------------------------------------------------------|
| Datos disponibles | Dos archivos CSV: créditos y tarjetas, ambos con 10.127 registros. | Permiten integrar información financiera y de comportamiento por id_cliente. |
| Variable objetivo | falta_pago con valores Y/N.                                        | Permite formular un problema supervisado de clasificación binaria.           |
| Recursos técnicos | Python, GitHub, DVC, PyTest y notebooks iniciales.                 | Facilitan automatización y reproducibilidad.                                 |
| Riesgos iniciales | Valores nulos, desbalance de clases y valores atípicos.            | Deben controlarse mediante validaciones y reglas de preparación.             |

### Determinación de los objetivos del proyecto

El objetivo técnico de la primera iteración es producir una versión reproducible de las fases iniciales del proyecto: comprensión y preparación de datos. El producto esperado es un conjunto de artefactos ejecutables que permitan generar reportes, validar calidad y producir un dataset integrado preparado para el modelado.

| Objetivo                     | Criterio de aceptación                                                            |
|------------------------------|-----------------------------------------------------------------------------------|
| Replicar entorno de trabajo  | El entorno instala las dependencias mínimas y permite ejecutar scripts y tests.   |
| Automatizar visualización    | Los gráficos se exportan al directorio reports/figures sin depender del notebook. |
| Automatizar calidad de datos | Se generan reportes .md, .csv y .json con reglas de calidad trazables.            |

|                         |                                                                               |
|-------------------------|-------------------------------------------------------------------------------|
| Automatizar preparación | Se exporta un dataset procesado único en data/processed/datos_integrados.csv. |
| Integrar pipeline DVC   | dvc.yaml contiene etapas, dependencias y salidas reproducibles.               |

## Definir plan del proyecto: Product Backlog

| ID   | Historia de usuario                                                                                         | Valor | Puntos | Criterio de aceptación                           |
|------|-------------------------------------------------------------------------------------------------------------|-------|--------|--------------------------------------------------|
| HU01 | Como equipo técnico, quiero replicar el entorno de trabajo para ejecutar el proyecto de forma reproducible. | Alta  | 3      | Entorno creado y scripts ejecutables.            |
| HU02 | Como product owner, quiero redefinir la visión del proyecto para orientar el MVP a producción.              | Alta  | 5      | Visión y objetivos documentados en la memoria.   |
| HU03 | Como equipo técnico, quiero versionar los datos originales con DVC para garantizar trazabilidad.            | Alta  | 5      | Datos incorporados y pipeline preparado.         |
| HU04 | Como analista, quiero generar visualizaciones exportables para comprender los datos.                        | Media | 5      | Figuras generadas en reports/figures.            |
| HU05 | Como responsable de calidad, quiero validar los datos con tests automatizados.                              | Alta  | 8      | Reporte de calidad y pruebas PyTest disponibles. |
| HU06 | Como científico de datos, quiero preparar un dataset integrado para futuras fases de modelado.              | Alta  | 8      | Archivo datos_integrados.csv generado.           |
| HU07 | Como equipo DataOps, quiero orquestar las tareas con DVC para reproducir el flujo completo.                 | Alta  | 8      | dvc repro ejecuta las etapas definidas.          |

## Sprint Backlog de la primera iteración

| ID  | Tarea                                                               | Historia | Estado                   |
|-----|---------------------------------------------------------------------|----------|--------------------------|
| T01 | Crear estructura del repositorio: data, src, tests, reports y docs. | HU01     | Hecho                    |
| T02 | Migrar visualizaciones desde CD01_Visualizacion.ipynb a script.     | HU04     | Hecho                    |
| T03 | Definir reglas de calidad y generar reporte automatizado.           | HU05     | Hecho                    |
| T04 | Crear tests PyTest de columnas, unicidad, integridad y rangos.      | HU05     | Hecho                    |
| T05 | Migrar transformaciones desde CD02_Procesamiento.ipynb a script.    | HU06     | Hecho                    |
| T06 | Definir pipeline DVC con etapas y salidas.                          | HU07     | Hecho                    |
| T07 | Documentar resultados en memoria de trabajo.                        | HU02     | En revisión              |
| T08 | Agregar capturas del tablero GitHub Projects y ejecución local.     | HU02     | Pendiente del estudiante |

## [B] Comprensión de los datos


### Recolección y descripción inicial

Se cuenta con dos datasets en formato CSV separados por punto y coma. Ambos comparten el atributo id\_cliente, que permite la integración posterior.


| Dataset            | Filas | Columnas | Descripción                                                                      |
|--------------------|-------|----------|----------------------------------------------------------------------------------|
| datos_creditos.csv | 10127 | 12       | Información del crédito, condiciones financieras y variable objetivo falta_pago. |
| datos_tarjetas.csv | 10127 | 11       | Información de tarjetas de crédito y actividad del cliente.                      |

### Exploración inicial

La variable objetivo falta\_pago presenta la siguiente distribución absoluta: {'N': 8359, 'Y': 1768}. En términos porcentuales, la clase N representa 82.54% y la clase Y representa 17.46%. Esto evidencia un desbalance que deberá considerarse en la fase de modelado.



**Figura 1.** Distribución de la variable objetivo falta\_pago.



**Figura 2.** Porcentaje de valores nulos por atributo.

## Verificación de calidad de datos

La evaluación de calidad se implementó mediante el script `src/validar_calidad.py` y se complementó con tests PyTest en `tests/test_calidad_datos.py`. Se definieron reglas de completitud, unicidad, integridad referencial, validez y consistencia interna.

| Dimensión               | Regla                                            | Resultado | Errores | Total  | Tasa     |
|-------------------------|--------------------------------------------------|-----------|---------|--------|----------|
| Completitud estructural | Columnas esperadas en créditos                   | OK        | 0       | 12     | 0.0      |
| Completitud estructural | Columnas esperadas en tarjetas                   | OK        | 0       | 11     | 0.0      |
| Completitud             | Valores nulos en créditos                        | OK        | 1249    | 121524 | 0.010278 |
| Completitud             | Valores nulos en tarjetas                        | OK        | 0       | 111397 | 0.0      |
| Unicidad                | id_cliente único en créditos                     | OK        | 0       | 10127  | 0.0      |
| Unicidad                | id_cliente único en tarjetas                     | OK        | 0       | 10127  | 0.0      |
| Consistencia            | Integridad referencial entre créditos y tarjetas | OK        | 0       | 10127  | 0.0      |

|              |                                                       |    |    |       |          |
|--------------|-------------------------------------------------------|----|----|-------|----------|
| Validez      | Edad entre 18 y 90 años                               | OK | 4  | 10127 | 0.000395 |
| Consistencia | pct_ingreso coherente con importe_solicitado/ingresos | OK | 37 | 10127 | 0.003654 |
| Validez      | falta_pago en {Y,N}                                   | OK | 0  | 10127 | 0.0      |

El detalle completo de las 15 reglas queda registrado en reports/calidad\_datos.md, reports/calidad\_datos.csv y reports/calidad\_datos.json.

Principales hallazgos: existen 1.249 valores nulos en créditos sobre 121.524 celdas, concentrados en antigüedad\_empleado y tasa\_interes; no se encontraron duplicados de id\_cliente; la integridad referencial entre ambas tablas es completa; se detectaron pocos valores atípicos en edad y antigüedad laboral, dentro de umbrales tolerables.

## [C] Preparación de los datos

### Transformaciones aplicadas

| Tipo de transformación | Descripción                                                       | Justificación                                                                               |
|------------------------|-------------------------------------------------------------------|---------------------------------------------------------------------------------------------|
| Selección de atributos | Eliminación de nivel_tarjeta.                                     | Variable con fuerte predominio de una categoría; se retira en esta versión inicial.         |
| Filtro de filas        | Conservación de registros con edad < 90.                          | Reduce impacto de valores extremos no plausibles para el escenario.                         |
| Tratamiento de nulos   | Eliminación de filas con valores nulos en créditos.               | Mantiene coherencia con la libreta inicial de procesamiento y genera dataset sin ausencias. |
| Integración            | Unión interna por id_cliente.                                     | Asegura que cada registro final tenga información crediticia y de tarjeta.                  |
| Recodificación         | estado_civil_N, estado_credito_N, antigüedad_empleado_N y edad_N. | Facilita el uso posterior en modelado.                                                      |
| Nuevos atributos       | ratio_gasto_limite_tc y falta_pago_bin.                           | Aporta variable financiera derivada y objetivo binario.                                     |

| Métrica                      | Valor |
|------------------------------|-------|
| Filas antes de preparar      | 10127 |
| Filas después de preparar    | 8899  |
| Columnas después de preparar | 23    |
| Registros no conservados     | 1228  |
| Valores nulos finales        | 0     |
| Duplicados finales           | 0     |

## Pipeline DataOps con DVC

El pipeline propuesto contiene tres etapas encadenadas: visualizacion, validacion\_calidad y preparacion\_datos. Cada etapa declara comandos, dependencias y salidas, permitiendo reproducir el flujo con dvc repro.

| Etapas             | Comando                               | Salidas principales                                               |
|--------------------|---------------------------------------|-------------------------------------------------------------------|
| visualizacion      | python src/generar_visualizaciones.py | reports/figures, reports/resumen_datos.md                         |
| validacion_calidad | python src/validar_calidad.py         | reports/calidad_datos.md, .json y .csv                            |
| preparacion_datos  | python src/preparar_datos.py          | data/processed/datos_integrados.csv, reports/preparacion_datos.md |

## Ejecución de pruebas

Se ejecutó la suite PyTest incluida en el proyecto. Resultado: 6 pruebas superadas de 6 ejecutadas.

| Prueba                              | Propósito                               |
|-------------------------------------|-----------------------------------------|
| test_creditos_columnas_obligatorias | Verificar columnas mínimas de créditos. |

|                                                         |                                                              |
|---------------------------------------------------------|--------------------------------------------------------------|
| test_tarjetas_columnas_obligatorias                     | Verificar columnas mínimas de tarjetas.                      |
| test_ids_unicos_e_integridad_referencial                | Validar unicidad e igualdad de identificadores entre tablas. |
| test_valores_validos_variable_objetivo_y_estado_credito | Validar dominios de variables clave.                         |
| test_rangos_numericos_basicos                           | Validar rangos financieros básicos.                          |
| test_dataset_procesado_sin_nulos_si_existe              | Validar salida procesada sin nulos ni duplicados.            |

## Conclusiones y próximos pasos

La Actividad Práctica I permite pasar de una experimentación en notebooks a una primera estructura reproducible de DataOps. La automatización realizada mejora la trazabilidad, facilita la repetición de resultados y deja preparado un dataset integrado para la siguiente iteración del proyecto.

Como próximos pasos se recomienda completar la evidencia visual de GitHub y DVC, versionar formalmente los datos con dvc add, sincronizar el repositorio remoto, y preparar la Actividad Práctica II incorporando modelado, evaluación, despliegue y monitoreo.

## Anexos

```
(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>python -m pytest -q
.....
6 passed in 15.86s [100%]
(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>
```

**Figura 3.** Ejecución de pruebas automatizadas con PyTest

```
Running stage 'visualizacion':
> python src/generar_visualizaciones.py
Visualizaciones exportadas en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\reports\figures
Resumen exportado en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\reports\resumen_datos.md

Running stage 'validacion_calidad':
> python src/validar_calidad.py
Validación finalizada.
Updating lock file 'dvc.lock'

Running stage 'preparacion_datos':
> python src/preparar_datos.py
Dataset preparado exportado en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\data\processed\datos_integrados.csv
Filas: 8899 | Columnas: 23
Updating lock file 'dvc.lock'
Use 'dvc push' to send your updates to remote storage.

(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>
```

**Figura 4.** Ejecución del pipeline de datos mediante DVC.