

Actividad Práctica I

Metodologías de Gestión y Diseño de Proyectos Big Data

Máster en Big Data y Data Science - 13MBID

Campo	Contenido
Nombre completo	José Escorcía Gutiérrez
Enlace al repositorio en GitHub	https://github.com/josescorcia/13MBID-AP1-Jose-Escorcía.git
Enlace a la herramienta de gestión de tareas	https://github.com/users/josescorcia/projects/1/views/1
Fecha	08/07/2026

Resumen ejecutivo

La presente memoria documenta la primera iteración de automatización de un proyecto de ciencia de datos orientado a predecir la mora futura de créditos de una entidad financiera. El trabajo combina CRISP-DM para organizar las fases analíticas, Scrum para gestionar el backlog y DataOps para automatizar tareas repetibles de visualización, validación y preparación de datos.

En esta versión se implementaron scripts independientes de las libretas, tests automatizados con PyTest, reportes de calidad, visualizaciones exportables y un pipeline DVC con tres etapas: visualización, validación de calidad y preparación de datos.

Resultado	Valor
Registros en datos de créditos	10127
Registros en datos de tarjetas	10127
Registros en dataset procesado	8899
Columnas en dataset procesado	23
Tests PyTest ejecutados	6
Tests PyTest superados	6
Reglas de calidad evaluadas	15
Reglas en estado OK	15

[A] Comprensión del negocio

Determinar los objetivos de la organización

La organización corresponde a una entidad financiera que busca obtener conocimiento a partir de su base histórica de créditos otorgados y de información complementaria sobre tarjetas de crédito. El objetivo de negocio es mejorar la capacidad de anticipar clientes con riesgo de mora para apoyar decisiones comerciales y de riesgo crediticio.

Para esta primera actividad práctica, el objetivo se amplía desde la construcción de un MVP hacia la estandarización del proceso de ciencia de datos: versionar datos, reproducir experimentos, automatizar flujos, separar scripts de notebooks, documentar decisiones y preparar una base sólida para futuras fases de modelado y despliegue.

Evaluación de la situación

Elemento	Situación identificada	Implicación para el proyecto
Datos disponibles	Dos archivos CSV: créditos y tarjetas, ambos con 10.127 registros.	Permiten integrar información financiera y de comportamiento por id_cliente.
Variable objetivo	falta_pago con valores Y/N.	Permite formular un problema supervisado de clasificación binaria.
Recursos técnicos	Python, GitHub, DVC, PyTest y notebooks iniciales.	Facilitan automatización y reproducibilidad.
Riesgos iniciales	Valores nulos, desbalance de clases y valores atípicos.	Deben controlarse mediante validaciones y reglas de preparación.

Determinación de los objetivos del proyecto

El objetivo técnico de la primera iteración es producir una versión reproducible de las fases iniciales del proyecto: comprensión y preparación de datos. El producto esperado es un conjunto de artefactos ejecutables que permitan generar reportes, validar calidad y producir un dataset integrado preparado para el modelado.

Objetivo	Criterio de aceptación
Replicar entorno de trabajo	El entorno instala las dependencias mínimas y permite ejecutar scripts y tests.
Automatizar visualización	Los gráficos se exportan al directorio reports/figures sin depender del notebook.
Automatizar calidad de datos	Se generan reportes .md, .csv y .json con reglas de calidad trazables.

Automatizar preparación	Se exporta un dataset procesado único en data/processed/datos_integrados.csv.
Integrar pipeline DVC	dvc.yaml contiene etapas, dependencias y salidas reproducibles.

Definir plan del proyecto: Product Backlog

ID	Historia de usuario	Valor	Puntos	Criterio de aceptación
HU01	Como equipo técnico, quiero replicar el entorno de trabajo para ejecutar el proyecto de forma reproducible.	Alta	3	Entorno creado y scripts ejecutables.
HU02	Como product owner, quiero redefinir la visión del proyecto para orientar el MVP a producción.	Alta	5	Visión y objetivos documentados en la memoria.
HU03	Como equipo técnico, quiero versionar los datos originales con DVC para garantizar trazabilidad.	Alta	5	Datos incorporados y pipeline preparado.
HU04	Como analista, quiero generar visualizaciones exportables para comprender los datos.	Media	5	Figuras generadas en reports/figures.
HU05	Como responsable de calidad, quiero validar los datos con tests automatizados.	Alta	8	Reporte de calidad y pruebas PyTest disponibles.
HU06	Como científico de datos, quiero preparar un dataset integrado para futuras fases de modelado.	Alta	8	Archivo datos_integrados.csv generado.
HU07	Como equipo DataOps, quiero orquestar las tareas con DVC para reproducir el flujo completo.	Alta	8	dvc repro ejecuta las etapas definidas.

Sprint Backlog de la primera iteración

ID	Tarea	Historia	Estado
T01	Crear estructura del repositorio: data, src, tests, reports y docs.	HU01	Hecho
T02	Migrar visualizaciones desde CD01_Visualizacion.ipynb a script.	HU04	Hecho
T03	Definir reglas de calidad y generar reporte automatizado.	HU05	Hecho
T04	Crear tests PyTest de columnas, unicidad, integridad y rangos.	HU05	Hecho
T05	Migrar transformaciones desde CD02_Procesamiento.ipynb a script.	HU06	Hecho
T06	Definir pipeline DVC con etapas y salidas.	HU07	Hecho
T07	Documentar resultados en memoria de trabajo.	HU02	Hecho
T08	Agregar capturas del tablero GitHub Projects y ejecución local.	HU02	Hecho

[B] Comprensión de los datos

Recolección y descripción inicial

Se cuenta con dos datasets en formato CSV separados por punto y coma. Ambos comparten el atributo id_cliente, que permite la integración posterior.

Dataset	Filas	Columnas	Descripción
datos_creditos.csv	10127	12	Información del crédito, condiciones financieras y variable objetivo falta_pago.
datos_tarjetas.csv	10127	11	Información de tarjetas de crédito y actividad del cliente.

Exploración inicial

La variable objetivo falta_pago presenta la siguiente distribución absoluta: {'N': 8359, 'Y': 1768}. En términos porcentuales, la clase N representa 82.54% y la clase Y representa 17.46%. Esto evidencia un desbalance que deberá considerarse en la fase de modelado.




Figura 1. Distribución de la variable objetivo falta_pago.




Figura 2. Porcentaje de valores nulos por atributo.

Verificación de calidad de datos

La evaluación de calidad se implementó mediante el script src/validar_calidad.py y se complementó con tests PyTest en tests/test_calidad_datos.py. Se definieron reglas de completitud, unicidad, integridad referencial, validez y consistencia interna.

Dimensión	Regla	Resultado	Errores	Total	Tasa
Completitud estructural	Columnas esperadas en créditos	OK	0	12	0.0
Completitud estructural	Columnas esperadas en tarjetas	OK	0	11	0.0
Completitud	Valores nulos en créditos	OK	1249	121524	0.010278
Completitud	Valores nulos en tarjetas	OK	0	111397	0.0
Unicidad	id_cliente único en créditos	OK	0	10127	0.0
Unicidad	id_cliente único en tarjetas	OK	0	10127	0.0
Consistencia	Integridad referencial entre créditos y tarjetas	OK	0	10127	0.0

Validez	Edad entre 18 y 90 años	OK	4	10127	0.000395
Consistencia	pct_ingreso coherente con importe_solicitado/ingresos	OK	37	10127	0.003654
Validez	falta_pago en {Y,N}	OK	0	10127	0.0

El detalle completo de las 15 reglas queda registrado en reports/calidad_datos.md, reports/calidad_datos.csv y reports/calidad_datos.json.

Principales hallazgos: existen 1.249 valores nulos en créditos sobre 121.524 celdas, concentrados en antigüedad_empleado y tasa_interes; no se encontraron duplicados de id_cliente; la integridad referencial entre ambas tablas es completa; se detectaron pocos valores atípicos en edad y antigüedad laboral, dentro de umbrales tolerables.

[C] Preparación de los datos

Transformaciones aplicadas

Tipo de transformación	Descripción	Justificación
Selección de atributos	Eliminación de nivel_tarjeta.	Variable con fuerte predominio de una categoría; se retira en esta versión inicial.
Filtro de filas	Conservación de registros con edad < 90.	Reduce impacto de valores extremos no plausibles para el escenario.
Tratamiento de nulos	Eliminación de filas con valores nulos en créditos.	Mantiene coherencia con la libreta inicial de procesamiento y genera dataset sin ausencias.
Integración	Unión interna por id_cliente.	Asegura que cada registro final tenga información crediticia y de tarjeta.
Recodificación	estado_civil_N, estado_credito_N, antigüedad_empleado_N y edad_N.	Facilita el uso posterior en modelado.
Nuevos atributos	ratio_gasto_limite_tc y falta_pago_bin.	Aporta variable financiera derivada y objetivo binario.

Métrica	Valor
Filas antes de preparar	10127
Filas después de preparar	8899
Columnas después de preparar	23
Registros no conservados	1228
Valores nulos finales	0
Duplicados finales	0

Pipeline DataOps con DVC

El pipeline propuesto contiene tres etapas encadenadas: visualizacion, validacion_calidad y preparacion_datos. Cada etapa declara comandos, dependencias y salidas, permitiendo reproducir el flujo con dvc repro.

Etapas	Comando	Salidas principales
visualizacion	python src/generar_visualizaciones.py	reports/figures, reports/resumen_datos.md
validacion_calidad	python src/validar_calidad.py	reports/calidad_datos.md, .json y .csv
preparacion_datos	python src/preparar_datos.py	data/processed/datos_integrados.csv, reports/preparacion_datos.md

Ejecución de pruebas

Se ejecutó la suite PyTest incluida en el proyecto. Resultado: 6 pruebas superadas de 6 ejecutadas.

Prueba	Propósito
test_creditos_columnas_obligatorias	Verificar columnas mínimas de créditos.

test_tarjetas_columnas_obligatorias	Verificar columnas mínimas de tarjetas.
test_ids_unicos_e_integridad_referencial	Validar unicidad e igualdad de identificadores entre tablas.
test_valores_validos_variable_objetivo_y_estado_credito	Validar dominios de variables clave.
test_rangos_numericos_basicos	Validar rangos financieros básicos.
test_dataset_procesado_sin_nulos_si_existe	Validar salida procesada sin nulos ni duplicados.

Conclusiones y próximos pasos

La Actividad Práctica I permite pasar de una experimentación en notebooks a una primera estructura reproducible de DataOps. La automatización realizada mejora la trazabilidad, facilita la repetición de resultados y deja preparado un dataset integrado para la siguiente iteración del proyecto.

Como próximos pasos se recomienda completar la evidencia visual de GitHub y DVC, versionar formalmente los datos con `dvc add`, sincronizar el repositorio remoto, y preparar la Actividad Práctica II incorporando modelado, evaluación, despliegue y monitoreo.

Anexos

```
(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>python -m pytest -q
.....
6 passed in 15.86s [100%]
(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>
```

Figura 3. Ejecución de pruebas automatizadas con PyTest

```
Running stage 'visualizacion':
> python src/generar_visualizaciones.py
Visualizaciones exportadas en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\reports\figures
Resumen exportado en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\reports\resumen_datos.md

Running stage 'validacion_calidad':
> python src/validar_calidad.py
Validación finalizada.
Updating lock file 'dvc.lock'

Running stage 'preparacion_datos':
> python src/preparar_datos.py
Dataset preparado exportado en: G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable\data\processed\datos_integrados.csv
Filas: 8899 | Columnas: 23
Updating lock file 'dvc.lock'
Use 'dvc push' to send your updates to remote storage.

(.venv) G:\Otros ordenadores\Mi portátil\Maestria\Metodologías de gestión y diseño proyectos BD\Entregables act1\ap1_13mbid_entregable>
```

Figura 4. Ejecución del pipeline de datos mediante DVC.